

Aprendizado Supervisionado

Parte 1

Classificação com k-NN


Profa Silvia Moraes



Roteiro

- Relembrando
 - Machine Learning: Aprendizado Supervisionado
 - Tarefas Preditivas
- Classificação
 - Classificadores Lineares
 - Algoritmo k-NN

Subáreas da Inteligência Artificial



Aprendizado Supervisionado

- Exige que os **dados** estejam **rotulados** (anotados com suas respectivas classes/valores de saída)
- Os algoritmos que seguem esse tipo de aprendizado recebem pares de valores:
 - os dados de entrada (x) e
 - os valores de saída (rótulos) correspondentes (y).



Dataset Anotado

Aprendizado Supervisionado

Em um conjunto de dados (exemplos) rotulado :

- Cada dado corresponde a um indivíduo do domínio e é formado por uma tupla contendo características (features).

Atributo de entrada
(atributo previsor)

sepal length	sepal width	petal length	petal width	class
5,1	3,5	1,4	0,2	Iris-setosa
4,9	3,0	1,4	0,2	Iris-setosa
7,0	3,2	4,7	7,1	Iris-versicolor
6,4	3,2	4,5	1,5	Iris-versicolor
6,3	3,3	6,0	2,5	Iris-virginica
5,8	2,7	5,1	1,9	Iris-virginica


Atributo de saída
(atributo alvo ou meta)

Rótulo
(Classes)



Aprendizado Supervisionado

- O objetivo é encontrar um modelo capaz de mapear os valores de entrada (x) nos valores de saída y .
- Em outras palavras, que aproxime f , tal que $f(x) = y$.
- Supervisão: ajuste usando o erro em relação à saída esperada.





Modelo Probabilístico

Aprendizado Supervisionado

- **Tarefa preditiva:** encontra uma função (modelo) a partir dos dados de treino que possa ser usada para prever um rótulo (classe) ou valor de um novo exemplo.
- Pode ser:
 - **classificação** (rótulos discretos)
 - **regressão** (rótulos contínuos)

Classificação





- É o processo de automaticamente atribuir rótulos a dados.
- Pode ser do tipo
 - Binária: possui apenas duas classes
 - Multiclasse: possui mais de duas classes
- Pode atribuir
 - Um único rótulo (single label)
 - Vários rótulos (multi-label)






Regressão


- É o processo de automaticamente predizer novos valores y .
- Neste caso, os dados são anotados com valores.



Regressão



Classificação




Classificação



Como classificar Gafanhotos ?


Classificação

Se os dados desses insetos fossem estruturados, que atributos/características seriam mais importantes e significativos para a classificação?




Classificação

Se os dados desses insetos fossem estruturados, que atributos/características seriam mais importantes e significativos para a classificação?



Classificação




Se tivermos um **conjunto de dados anotados com as classes dos gafanhotos**, poderemos aplicar um algoritmo de classificação para prever a classe de novos insetos desse tipo.

ID	Compr. Abdômen	Compr. Antenas	Classe	ID	Compr. Abdômen	Compr. Antenas	Classe
1	2,7	5,5	Gafanhoto	6	2,9	1,9	Gafanhoto
2	8,0	9,1	Esperança	7	6,1	6,6	Esperança
3	0,9	4,7	Gafanhoto	8	0,5	1,0	Gafanhoto
4	1,1	3,1	Gafanhoto	9	8,3	6,6	Esperança
5	5,4	8,5	Esperança	10	8,1	4,7	Esperança

Qual a classe de um inseto com comprimento 5,1 de abdômen e 7,0 mm de antenas?

Classificação




Qual a classe de um inseto com comprimento 5,1 de abdômen e 7,0 mm de antenas?

Classificação

Classificador Linear Simples

Se o exemplo desconhecido está acima da linha
Então a classe é **Esperança**
Senão a classe é **Gafanhoto**




Classificação

Classificador Linear

Pode ser usado para mais dimensões.


Nesse caso, a divisão não será por uma reta (linha) mas por um hiperplano .




Classificação

Classificador Linear


Limitação: resolve apenas problemas cujas classes são linearmente separáveis.



Classificação Perfeita



Classificação Muito Boa




Classificação Inútil

Classificação

Classificador Linear

Exemplo: **Planta Iris**


- 150 amostras: Dataset Balanceado
 - 50 Iris Setosa,
 - 50 Iris Virginica e
 - 50 Iris Versicolor
- Podemos generalizar o classificador para N classes, encontrando N-1 hiperplanos:
 1. O primeiro hiperplano separa a Setosa das outras duas Versicolor/Virginica
 2. O segundo hiperplano separa Versicolor de Virginica



Algoritmo k-NN

K- Nearest Neighbour :
algoritmo dos k vizinhos
mais próximos.

Considera os objetos mais
próximos com
características semelhantes
para prever a classe de
um novo dado.



Algoritmo k-NN

- Algoritmo baseado em memória (Lazy)
 - Etapa de Treinamento:
 - **Não gera modelo:** apenas memorização dos dados rotulados
 - Etapa de Generalização:
 - Classifica um novo dado levando em consideração os k vizinhos mais próximos.
 - Usa uma medida de distância para calcular a proximidade dos dados vizinhos (distância euclidiana é bem usual).
 - Cada vizinho k próximo ao dado vota em uma classe.
 - A classe mais votada passa a ser a do novo dado.

Algoritmo k-NN

Inicialização

Preparar o conjunto de dados (treinamento e teste)

Informar o valor de k

Para cada nova amostra do conjunto de teste faça

{


Calcular a distância para todas as amostras do conjunto de treinamento

Determinar o conjunto das k amostras mais próximas

Determinar o rótulo mais representativo entre os k vizinhos

}

retornar o conjunto de teste rotulado




Algoritmo k-NN

Exemplo:

ID	Atributo1	Atributo2	Classe
1	5	9	A
2	7	9	A
3	8	9	A
4	9	8	A
5	2	5	B
6	4	4	B
7	1	3	B
8	2	3	B
9	5	2	?

- Aplicar o algoritmo para $k=3$
- Usar distância de Manhattan (para simplificar o cálculo)



Algoritmo k-NN

Exemplo:

ID	Atributo1	Atributo2	Classe		Amostra,DadoNovo	Distancia	Valor Distância
1	5	9	A		1,9	$ 5-5 + 9-2 $	7
2	7	9	A		2,9	$ 7-5 + 9-2 $	9
3	8	9	A		3,9	$ 8-5 + 9-2 $	10
4	9	8	A		4,9	$ 9-5 + 8-2 $	10
5	2	5	B		5,9	$ 2-5 + 5-2 $	6
6	4	4	B		6,9	$ 4-5 + 4-2 $	3
7	1	3	B		7,9	$ 1-5 + 3-2 $	5
8	2	3	B		8,9	$ 2-5 + 3-2 $	4
9	5	2	?				

- Aplicar o algoritmo para $k=3$
- Usar distância de Manhattan (para simplificar o cálculo)

Algoritmo k-NN

Exemplo:

ID	Atributo1	Atributo2	Classe		Amostra,DadoNovo	Distancia	Valor Distância
1	5	9	A		1,9	$ 5-5 + 9-2 $	7
2	7	9	A		2,9	$ 7-5 + 9-2 $	9
3	8	9	A		3,9	$ 8-5 + 9-2 $	10
4	9	8	A		4,9	$ 9-5 + 8-2 $	10
5	2	5	B		5,9	$ 2-5 + 5-2 $	6
6	4	4	B		6,9	$ 4-5 + 4-2 $	3
7	1	3	B		7,9	$ 1-5 + 3-2 $	5
8	2	3	B		8,9	$ 2-5 + 3-2 $	4
9	5	2	? B				

B é classe predominante dos 3 vizinhos mais próximos

- Aplicar o algoritmo para $k=3$
- Usar distância de Manhattan (para simplificar o cálculo)

Algoritmo k-NN

- **Aspectos Positivos**

- Treinamento é simples (apenas armazenamento dos objetos rotulados);
- Constrói aproximações locais da função objetivo, pois são diferentes para cada objeto novo que foi classificado;
- Aplicável mesmo em problemas complexos;
- Incremental (quando novas amostras de treinamento estão disponíveis, basta memorizá-las).

Algoritmo k-NN

- **Aspectos Negativos**

- Não gera um modelo
- Dependente da medida de distância (importante normalizar os dados)
- Predição pode ser custosa para muito objetos
- Alta dimensionalidade dos atributos afeta negativamente os algoritmos baseados em distância (quanto maior o número de atributos mais a distância do mais próximo aproxima-se do mais distante).

Referências

Este material foi construído com base no material sobre DataMining dos professores Eamonn Keogh(University of California), Rodrigues Barros, Duncan e Renata de Paris e também nos capítulos:

- 4 - Inteligência Artificial: Uma abordagem de Aprendizagem de Máquina: Facelli e outros.
- 18 do livro Artificial Intelligence a Modern Approach: Russel & Norvig